

# 大模型性能测试报告

Qwen3.8-27B · 2026-09-09

42 / 42

已完成测试组合

672 / 672

性能请求协议完成

0

未决性能请求

## 01 测试条件与模式验证

输入字符档位 1,024 / 2,048 / 4,096 / 8,192 / 16,384 / 32,768 / 65,536

执行计划 并发 1 / 5 / 10，每组合 3 轮；先关闭思考，再开启思考

预检与预热 2 次独立模式预检；本次未启用独立预热

### 关闭思考

HTTP 接受参数：是；预检成功。

### 开启思考

HTTP 接受参数：是；预检成功。

已观测到思考内容或服务返回的思考 Token。

## 02 双模式对照 · 关键场景

相同输入 1,024 字符 · 并发 1 · 每模式 3 个样本。全量对照见第 2-3 页。

### 关闭思考

输出预算 512 Token

TTFT P50 6.81 ms

TTFO P50 6.81 ms

单请求输出速率 P50 875.79 tok/s

实际输出 Token P50 12.00

### 开启思考

输出预算 4096 Token

TTFT P50 6.60 ms

TTFO P50 14.09 ms

单请求输出速率 P50 848.47 tok/s

实际输出 Token P50 18.00

关闭 / 开启思考的输出预算分别为 512 / 4,096 Token。这不是等预算对照，需结合实际输出长度与模式观测一起解释。

02-03 双模式对照 04-06 关闭思考 07-09 开启思考 10 性能分析 11 模型自评 12 口径与附录

# 双模式对照·延迟

21 个共同组合，全部展开

每行固定输入字符与并发，左右对照关闭 / 开启思考。单位：ms；统计量：P50。

关闭思考预算 512 Token；开启思考预算 4,096 Token。不同预算、实际输出长度及固定执行顺序均可能影响结果。

| 输入字符   | 并发 | 关闭 TTFT | 开启 TTFT | 关闭 TTFO | 开启 TTFO |
|--------|----|---------|---------|---------|---------|
| 1,024  | 1  | 6.81    | 6.60    | 6.81    | 14.09   |
| 1,024  | 5  | 7.61    | 7.33    | 7.61    | 14.51   |
| 1,024  | 10 | 8.45    | 8.43    | 8.45    | 15.31   |
| 2,048  | 1  | 6.78    | 6.44    | 6.78    | 14.00   |
| 2,048  | 5  | 7.30    | 7.21    | 7.30    | 14.55   |
| 2,048  | 10 | 8.08    | 8.30    | 8.08    | 15.43   |
| 4,096  | 1  | 6.53    | 6.74    | 6.53    | 14.26   |
| 4,096  | 5  | 7.24    | 7.09    | 7.24    | 14.33   |
| 4,096  | 10 | 7.94    | 8.54    | 7.94    | 15.32   |
| 8,192  | 1  | 6.80    | 6.84    | 6.80    | 14.37   |
| 8,192  | 5  | 7.54    | 7.43    | 7.54    | 14.71   |
| 8,192  | 10 | 8.11    | 8.33    | 8.11    | 15.46   |
| 16,384 | 1  | 6.78    | 6.83    | 6.78    | 14.34   |
| 16,384 | 5  | 7.34    | 7.73    | 7.34    | 15.01   |
| 16,384 | 10 | 7.90    | 7.90    | 7.90    | 14.91   |
| 32,768 | 1  | 6.84    | 6.87    | 6.84    | 14.37   |
| 32,768 | 5  | 7.28    | 7.66    | 7.28    | 15.65   |
| 32,768 | 10 | 10.94   | 8.22    | 10.94   | 15.30   |
| 65,536 | 1  | 6.74    | 6.30    | 6.74    | 13.87   |
| 65,536 | 5  | 7.41    | 7.86    | 7.41    | 15.22   |
| 65,536 | 10 | 8.25    | 8.52    | 8.25    | 15.91   |

## TTFT：首个语义文本

包含可识别的思考文本。不是首个 SSE 事件，也不代表服务端纯计算时间。

## TTFO：首个最终回答文本

没有最终回答或无法区分时为 N/A。与 TTFT 的差异不能直接归因为模型计算。

本表展示各组合 P50；未对各组合分位数求平均。各模式的 P95 与 E2E 见各自明细页。

# 双模式对照·输出

速率与实际输出长度共同阅读

速率单位：tok/s；统计量：P50。实际输出 Token 仅取服务端 usage。

| 输入字符   | 并发 | 关闭输出速率 | 开启输出速率 | 关闭输出 Token | 开启输出 Token |
|--------|----|--------|--------|------------|------------|
| 1,024  | 1  | 875.79 | 848.47 | 12.00      | 18.00      |
| 1,024  | 5  | 877.73 | 848.57 | 12.00      | 18.00      |
| 1,024  | 10 | 872.21 | 889.46 | 12.00      | 18.00      |
| 2,048  | 1  | 877.47 | 844.99 | 12.00      | 18.00      |
| 2,048  | 5  | 870.60 | 889.55 | 12.00      | 18.00      |
| 2,048  | 10 | 876.37 | 877.69 | 12.00      | 18.00      |
| 4,096  | 1  | 878.18 | 846.52 | 12.00      | 18.00      |
| 4,096  | 5  | 868.99 | 880.05 | 12.00      | 18.00      |
| 4,096  | 10 | 872.01 | 892.04 | 12.00      | 18.00      |
| 8,192  | 1  | 876.50 | 846.82 | 12.00      | 18.00      |
| 8,192  | 5  | 876.05 | 876.16 | 12.00      | 18.00      |
| 8,192  | 10 | 874.91 | 901.28 | 12.00      | 18.00      |
| 16,384 | 1  | 874.95 | 848.85 | 12.00      | 18.00      |
| 16,384 | 5  | 878.46 | 870.40 | 12.00      | 18.00      |
| 16,384 | 10 | 880.54 | 890.96 | 12.00      | 18.00      |
| 32,768 | 1  | 874.87 | 846.24 | 12.00      | 18.00      |
| 32,768 | 5  | 898.23 | 848.57 | 12.00      | 18.00      |
| 32,768 | 10 | 917.64 | 879.30 | 12.00      | 18.00      |
| 65,536 | 1  | 877.17 | 847.13 | 12.00      | 18.00      |
| 65,536 | 5  | 877.24 | 847.81 | 12.00      | 18.00      |
| 65,536 | 10 | 888.72 | 890.99 | 12.00      | 18.00      |

## 结果解释边界

关闭思考与开启思考的实际输出 Token P50 分别为 12 与 18，均低于配置的输出预算。本次输出较短，长输出场景的生成表现仍需单独测试。

单请求输出速率描述一次请求的生成速率；聚合输出吞吐描述组合测量窗口内的总输出，两者不能互换。各组合聚合吞吐见第 5、8 页。


completion\_tokens 按服务口径展示，不能直接称为最终回答 Token。达到输出上限、最终回答缺失及未知状态应独立保留。

# 关闭思考·请求与延迟

512 Token 输出预算 · 21 个组合

TTFT / TTFO / E2E 均为客户端观测，单位 ms。每个单元格依次列出 P50 / P95。

| 输入字符   | 并发 | 发起 / 成功 / 未决 | 成功率    | TTFT<br>P50 / P95 | TTFO<br>P50 / P95 | E2E<br>P50 / P95 |
|--------|----|--------------|--------|-------------------|-------------------|------------------|
| 1,024  | 1  | 3/3/0        | 100.0% | 6.81/6.88         | 6.81/6.88         | 19.47/19.52      |
| 1,024  | 5  | 15/15/0      | 100.0% | 7.61/8.26         | 7.61/8.26         | 20.22/20.92      |
| 1,024  | 10 | 30/30/0      | 100.0% | 8.45/9.75         | 8.45/9.75         | 21.49/22.30      |
| 2,048  | 1  | 3/3/0        | 100.0% | 6.78/7.12         | 6.78/7.12         | 19.17/19.80      |
| 2,048  | 5  | 15/15/0      | 100.0% | 7.30/7.73         | 7.30/7.73         | 20.10/20.71      |
| 2,048  | 10 | 30/30/0      | 100.0% | 8.08/9.13         | 8.08/9.13         | 20.65/21.59      |
| 4,096  | 1  | 3/3/0        | 100.0% | 6.53/6.58         | 6.53/6.58         | 19.15/19.24      |
| 4,096  | 5  | 15/15/0      | 100.0% | 7.24/9.36         | 7.24/9.36         | 20.22/21.97      |
| 4,096  | 10 | 30/30/0      | 100.0% | 7.94/8.61         | 7.94/8.61         | 20.67/21.83      |
| 8,192  | 1  | 3/3/0        | 100.0% | 6.80/6.81         | 6.80/6.81         | 19.46/19.48      |
| 8,192  | 5  | 15/15/0      | 100.0% | 7.54/8.73         | 7.54/8.73         | 20.17/21.65      |
| 8,192  | 10 | 30/30/0      | 100.0% | 8.11/9.28         | 8.11/9.28         | 20.77/21.60      |
| 16,384 | 1  | 3/3/0        | 100.0% | 6.78/6.87         | 6.78/6.87         | 19.52/19.95      |
| 16,384 | 5  | 15/15/0      | 100.0% | 7.34/8.24         | 7.34/8.24         | 20.09/20.82      |
| 16,384 | 10 | 30/30/0      | 100.0% | 7.90/8.69         | 7.90/8.69         | 20.41/20.99      |
| 32,768 | 1  | 3/3/0        | 100.0% | 6.84/6.90         | 6.84/6.90         | 19.48/19.49      |
| 32,768 | 5  | 15/15/0      | 100.0% | 7.28/8.07         | 7.28/8.07         | 19.73/21.37      |
| 32,768 | 10 | 30/30/0      | 100.0% | 10.94/12.59       | 10.94/12.59       | 23.05/25.35      |
| 65,536 | 1  | 3/3/0        | 100.0% | 6.74/6.78         | 6.74/6.78         | 19.33/19.38      |
| 65,536 | 5  | 15/15/0      | 100.0% | 7.41/8.27         | 7.41/8.27         | 19.98/20.85      |
| 65,536 | 10 | 30/30/0      | 100.0% | 8.25/9.74         | 8.25/9.74         | 20.59/22.10      |



所有组合状态均为 completed；各组合结束原因为完成。协议完成不代表回答完整或答案正确。C1 / C5 / C10 的样本数分别为 3 / 15 / 30。


# 关闭思考 · 输出与 Token

区分单请求速率、聚合吞吐和服务端用量

速率 tok/s；TPOT ms/Token。前两项依次列出 P50 / P95；四类 Token 均为 P50。

| 输入字符   | 并发 | 单请求速率<br>P50 / P95 | TPOT<br>P50 / P95 | 聚合吞吐    | 输入<br>Token | 输出<br>Token | 思考<br>Token | 缓存<br>Token |
|--------|----|--------------------|-------------------|---------|-------------|-------------|-------------|-------------|
| 1,024  | 1  | 875.79/876.85      | 1.14/1.14         | 625.23  | 100.00      | 12.00       | 0.00        | N/A         |
| 1,024  | 5  | 877.73/1006.50     | 1.14/1.16         | 2886.78 | 100.00      | 12.00       | 0.00        | N/A         |
| 1,024  | 10 | 872.21/986.11      | 1.14/1.19         | 5289.45 | 100.00      | 12.00       | 0.00        | N/A         |
| 2,048  | 1  | 877.47/902.69      | 1.14/1.14         | 620.40  | 100.00      | 12.00       | 0.00        | N/A         |
| 2,048  | 5  | 870.60/895.37      | 1.15/1.22         | 2909.24 | 100.00      | 12.00       | 0.00        | N/A         |
| 2,048  | 10 | 876.37/989.14      | 1.14/1.22         | 5453.47 | 100.00      | 12.00       | 0.00        | N/A         |
| 4,096  | 1  | 878.18/879.04      | 1.14/1.14         | 628.40  | 100.00      | 12.00       | 0.00        | N/A         |
| 4,096  | 5  | 868.99/1012.61     | 1.15/1.20         | 2822.96 | 100.00      | 12.00       | 0.00        | N/A         |
| 4,096  | 10 | 872.01/1011.96     | 1.14/1.22         | 5501.49 | 100.00      | 12.00       | 0.00        | N/A         |
| 8,192  | 1  | 876.50/878.90      | 1.14/1.14         | 617.26  | 100.00      | 12.00       | 0.00        | N/A         |
| 8,192  | 5  | 876.05/977.73      | 1.14/1.22         | 2834.79 | 100.00      | 12.00       | 0.00        | N/A         |
| 8,192  | 10 | 874.91/980.39      | 1.14/1.21         | 5380.65 | 100.00      | 12.00       | 0.00        | N/A         |
| 16,384 | 1  | 874.95/876.58      | 1.14/1.19         | 615.70  | 100.00      | 12.00       | 0.00        | N/A         |
| 16,384 | 5  | 878.46/988.29      | 1.14/1.18         | 2897.30 | 100.00      | 12.00       | 0.00        | N/A         |
| 16,384 | 10 | 880.54/989.32      | 1.12/1.19         | 5646.52 | 100.00      | 12.00       | 0.00        | N/A         |
| 32,768 | 1  | 874.87/877.83      | 1.14/1.14         | 620.72  | 100.00      | 12.00       | 0.00        | N/A         |
| 32,768 | 5  | 898.23/1073.68     | 1.11/1.27         | 2932.16 | 100.00      | 12.00       | 0.00        | N/A         |
| 32,768 | 10 | 917.64/1071.92     | 1.08/1.17         | 4521.46 | 100.00      | 12.00       | 0.00        | N/A         |
| 65,536 | 1  | 877.17/878.58      | 1.14/1.14         | 625.19  | 100.00      | 12.00       | 0.00        | N/A         |
| 65,536 | 5  | 877.24/1070.69     | 1.14/1.16         | 2875.65 | 100.00      | 12.00       | 0.00        | N/A         |
| 65,536 | 10 | 888.72/1010.62     | 1.11/1.24         | 5498.21 | 100.00      | 12.00       | 0.00        | N/A         |

关闭思考 · 聚合输出吞吐随输入规模变化



聚合吞吐是组合层级结果，没有 P50 / P95。缓存 Token 为 N/A 表示缺少观测，不表示缓存为零。输入字符数与实际输入 Token 分开展示。

# 关闭思考 · 证据完整性

失败、未知、截断与不可计算值均保留

| 输入字符   | 并发 | usage 覆盖 | 最终回答 / 未知 | 截断 | 速率有效样本 | 失败或跳过原因 |
|--------|----|----------|-----------|----|--------|---------|
| 1,024  | 1  | 100.0%   | 3/0       | 0  | 3      | —       |
| 1,024  | 5  | 100.0%   | 15/0      | 0  | 15     | —       |
| 1,024  | 10 | 100.0%   | 30/0      | 0  | 30     | —       |
| 2,048  | 1  | 100.0%   | 3/0       | 0  | 3      | —       |
| 2,048  | 5  | 100.0%   | 15/0      | 0  | 15     | —       |
| 2,048  | 10 | 100.0%   | 30/0      | 0  | 30     | —       |
| 4,096  | 1  | 100.0%   | 3/0       | 0  | 3      | —       |
| 4,096  | 5  | 100.0%   | 15/0      | 0  | 15     | —       |
| 4,096  | 10 | 100.0%   | 30/0      | 0  | 30     | —       |
| 8,192  | 1  | 100.0%   | 3/0       | 0  | 3      | —       |
| 8,192  | 5  | 100.0%   | 15/0      | 0  | 15     | —       |
| 8,192  | 10 | 100.0%   | 30/0      | 0  | 30     | —       |
| 16,384 | 1  | 100.0%   | 3/0       | 0  | 3      | —       |
| 16,384 | 5  | 100.0%   | 15/0      | 0  | 15     | —       |
| 16,384 | 10 | 100.0%   | 30/0      | 0  | 30     | —       |
| 32,768 | 1  | 100.0%   | 3/0       | 0  | 3      | —       |
| 32,768 | 5  | 100.0%   | 15/0      | 0  | 15     | —       |
| 32,768 | 10 | 100.0%   | 30/0      | 0  | 30     | —       |
| 65,536 | 1  | 100.0%   | 3/0       | 0  | 3      | —       |
| 65,536 | 5  | 100.0%   | 15/0      | 0  | 15     | —       |
| 65,536 | 10 | 100.0%   | 30/0      | 0  | 30     | —       |

## 最高全部请求成功的已测并发

| 输入字符 | 1,024 | 2,048 | 4,096 | 8,192 | 16,384 | 32,768 | 65,536 |
|------|-------|-------|-------|-------|--------|--------|--------|
| 已测并发 | 10    | 10    | 10    | 10    | 10     | 10     | 10     |

本次每档最高全部成功并发为 10，仅描述已测范围。它不是服务的绝对上限，也不是 SLA 或稳定容量结论。

### 已观测的完整性

本次所有性能请求均有 usage 和可识别最终回答，未记录截断或未决请求。

### 模式验证


参数被接受；未观测到思考不能证明已关闭。不能仅以 HTTP 200 判断模式生效。

# 开启思考·请求与延迟

4096 Token 输出预算 · 21 个组合

TTFT / TTFO / E2E 均为客户端观测，单位 ms。每个单元格依次列出 P50 / P95。

| 输入字符   | 并发 | 发起 / 成功 / 未决 | 成功率    | TTFT<br>P50 / P95 | TTFO<br>P50 / P95 | E2E<br>P50 / P95 |
|--------|----|--------------|--------|-------------------|-------------------|------------------|
| 1,024  | 1  | 3/3/0        | 100.0% | 6.60/6.72         | 14.09/14.24       | 26.64/26.85      |
| 1,024  | 5  | 15/15/0      | 100.0% | 7.33/7.93         | 14.51/15.25       | 26.92/28.27      |
| 1,024  | 10 | 30/30/0      | 100.0% | 8.43/9.84         | 15.31/16.93       | 28.07/29.62      |
| 2,048  | 1  | 3/3/0        | 100.0% | 6.44/6.97         | 14.00/14.52       | 25.97/27.16      |
| 2,048  | 5  | 15/15/0      | 100.0% | 7.21/7.82         | 14.55/15.33       | 26.55/28.76      |
| 2,048  | 10 | 30/30/0      | 100.0% | 8.30/9.27         | 15.43/16.79       | 27.95/29.69      |
| 4,096  | 1  | 3/3/0        | 100.0% | 6.74/6.86         | 14.26/14.38       | 26.93/27.04      |
| 4,096  | 5  | 15/15/0      | 100.0% | 7.09/7.68         | 14.33/14.96       | 26.31/28.64      |
| 4,096  | 10 | 30/30/0      | 100.0% | 8.54/9.19         | 15.32/16.44       | 28.08/29.23      |
| 8,192  | 1  | 3/3/0        | 100.0% | 6.84/6.94         | 14.37/14.47       | 27.01/27.15      |
| 8,192  | 5  | 15/15/0      | 100.0% | 7.43/9.91         | 14.71/17.45       | 27.50/30.06      |
| 8,192  | 10 | 30/30/0      | 100.0% | 8.33/9.43         | 15.46/16.52       | 27.55/29.27      |
| 16,384 | 1  | 3/3/0        | 100.0% | 6.83/7.08         | 14.34/14.60       | 26.75/26.99      |
| 16,384 | 5  | 15/15/0      | 100.0% | 7.73/8.57         | 15.01/16.09       | 27.44/28.55      |
| 16,384 | 10 | 30/30/0      | 100.0% | 7.90/8.91         | 14.91/16.48       | 27.62/28.91      |
| 32,768 | 1  | 3/3/0        | 100.0% | 6.87/7.05         | 14.37/14.58       | 26.99/27.22      |
| 32,768 | 5  | 15/15/0      | 100.0% | 7.66/8.91         | 15.65/16.39       | 27.95/29.19      |
| 32,768 | 10 | 30/30/0      | 100.0% | 8.22/9.29         | 15.30/16.83       | 27.85/28.79      |
| 65,536 | 1  | 3/3/0        | 100.0% | 6.30/6.88         | 13.87/14.34       | 26.43/26.49      |
| 65,536 | 5  | 15/15/0      | 100.0% | 7.86/8.66         | 15.22/16.18       | 27.93/28.72      |
| 65,536 | 10 | 30/30/0      | 100.0% | 8.52/10.74        | 15.91/18.20       | 27.40/31.27      |



所有组合状态均为 completed；各组合结束原因为完成。协议完成不代表回答完整或答案正确。C1 / C5 / C10 的样本数分别为 3 / 15 / 30。

# 开启思考 · 输出与 Token


区分单请求速率、聚合吞吐和服务端用量

速率 tok/s；TPOT ms/Token。前两项依次列出 P50 / P95；四类 Token 均为 P50。

| 输入字符   | 并发 | 单请求速率<br>P50 / P95 | TPOT<br>P50 / P95 | 聚合吞吐    | 输入<br>Token | 输出<br>Token | 思考<br>Token | 缓存<br>Token |
|--------|----|--------------------|-------------------|---------|-------------|-------------|-------------|-------------|
| 1,024  | 1  | 848.47/851.01      | 1.18/1.18         | 677.31  | 100.00      | 18.00       | 6.00        | N/A         |
| 1,024  | 5  | 848.57/925.58      | 1.18/1.20         | 3225.13 | 100.00      | 18.00       | 6.00        | N/A         |
| 1,024  | 10 | 889.46/998.00      | 1.12/1.25         | 6013.88 | 100.00      | 18.00       | 6.00        | N/A         |
| 2,048  | 1  | 844.99/951.83      | 1.18/1.19         | 696.60  | 100.00      | 18.00       | 6.00        | N/A         |
| 2,048  | 5  | 889.55/1017.08     | 1.12/1.25         | 3253.41 | 100.00      | 18.00       | 6.00        | N/A         |
| 2,048  | 10 | 877.69/969.76      | 1.13/1.21         | 6073.68 | 100.00      | 18.00       | 6.00        | N/A         |
| 4,096  | 1  | 846.52/921.13      | 1.18/1.18         | 681.04  | 100.00      | 18.00       | 6.00        | N/A         |
| 4,096  | 5  | 880.05/1032.15     | 1.14/1.23         | 3236.76 | 100.00      | 18.00       | 6.00        | N/A         |
| 4,096  | 10 | 892.04/978.37      | 1.12/1.22         | 6057.77 | 100.00      | 18.00       | 6.00        | N/A         |
| 8,192  | 1  | 846.82/847.32      | 1.18/1.18         | 667.58  | 100.00      | 18.00       | 6.00        | N/A         |
| 8,192  | 5  | 876.16/899.58      | 1.14/1.22         | 3143.81 | 100.00      | 18.00       | 6.00        | N/A         |
| 8,192  | 10 | 901.28/970.31      | 1.11/1.19         | 6212.08 | 100.00      | 18.00       | 6.00        | N/A         |
| 16,384 | 1  | 848.85/917.00      | 1.18/1.18         | 679.45  | 100.00      | 18.00       | 6.00        | N/A         |
| 16,384 | 5  | 870.40/1033.06     | 1.15/1.20         | 3177.68 | 100.00      | 18.00       | 6.00        | N/A         |
| 16,384 | 10 | 890.96/1004.42     | 1.12/1.20         | 6204.19 | 100.00      | 18.00       | 6.00        | N/A         |
| 32,768 | 1  | 846.24/848.22      | 1.18/1.18         | 665.21  | 100.00      | 18.00       | 6.00        | N/A         |
| 32,768 | 5  | 848.57/1005.06     | 1.18/1.26         | 3100.36 | 100.00      | 18.00       | 6.00        | N/A         |
| 32,768 | 10 | 879.30/971.18      | 1.13/1.20         | 6141.02 | 100.00      | 18.00       | 6.00        | N/A         |
| 65,536 | 1  | 847.13/899.11      | 1.18/1.18         | 685.59  | 100.00      | 18.00       | 6.00        | N/A         |
| 65,536 | 5  | 847.81/894.00      | 1.18/1.24         | 3172.73 | 100.00      | 18.00       | 6.00        | N/A         |
| 65,536 | 10 | 890.99/970.05      | 1.12/1.20         | 5928.77 | 100.00      | 18.00       | 6.00        | N/A         |

开启思考 · 聚合输出吞吐随输入规模变化

横轴：字符；C：并发



聚合吞吐是组合层级结果，没有 P50 / P95。缓存 Token 为 N/A 表示缺少观测，不表示缓存为零。输入字符数与实际输入 Token 分开展示。

# 开启思考 · 证据完整性

失败、未知、截断与不可计算值均保留

| 输入字符   | 并发 | usage 覆盖 | 最终回答 / 未知 | 截断 | 速率有效样本 | 失败或跳过原因 |
|--------|----|----------|-----------|----|--------|---------|
| 1,024  | 1  | 100.0%   | 3/0       | 0  | 3      | —       |
| 1,024  | 5  | 100.0%   | 15/0      | 0  | 15     | —       |
| 1,024  | 10 | 100.0%   | 30/0      | 0  | 30     | —       |
| 2,048  | 1  | 100.0%   | 3/0       | 0  | 3      | —       |
| 2,048  | 5  | 100.0%   | 15/0      | 0  | 15     | —       |
| 2,048  | 10 | 100.0%   | 30/0      | 0  | 30     | —       |
| 4,096  | 1  | 100.0%   | 3/0       | 0  | 3      | —       |
| 4,096  | 5  | 100.0%   | 15/0      | 0  | 15     | —       |
| 4,096  | 10 | 100.0%   | 30/0      | 0  | 30     | —       |
| 8,192  | 1  | 100.0%   | 3/0       | 0  | 3      | —       |
| 8,192  | 5  | 100.0%   | 15/0      | 0  | 15     | —       |
| 8,192  | 10 | 100.0%   | 30/0      | 0  | 30     | —       |
| 16,384 | 1  | 100.0%   | 3/0       | 0  | 3      | —       |
| 16,384 | 5  | 100.0%   | 15/0      | 0  | 15     | —       |
| 16,384 | 10 | 100.0%   | 30/0      | 0  | 30     | —       |
| 32,768 | 1  | 100.0%   | 3/0       | 0  | 3      | —       |
| 32,768 | 5  | 100.0%   | 15/0      | 0  | 15     | —       |
| 32,768 | 10 | 100.0%   | 30/0      | 0  | 30     | —       |
| 65,536 | 1  | 100.0%   | 3/0       | 0  | 3      | —       |
| 65,536 | 5  | 100.0%   | 15/0      | 0  | 15     | —       |
| 65,536 | 10 | 100.0%   | 30/0      | 0  | 30     | —       |

## 最高全部请求成功的已测并发

| 输入字符 | 1,024 | 2,048 | 4,096 | 8,192 | 16,384 | 32,768 | 65,536 |
|------|-------|-------|-------|-------|--------|--------|--------|
| 已测并发 | 10    | 10    | 10    | 10    | 10     | 10     | 10     |

本次每档最高全部成功并发为 10，仅描述已测范围。它不是服务的绝对上限，也不是 SLA 或稳定容量结论。

### 已观测的完整性

本次所有性能请求均有 usage 和可识别最终回答，未记录截断或未决请求。

### 模式验证

参数被接受；已观测到思考内容或思考 Token。不能仅以 HTTP 200 判断模式生效。

# 性能变化分析

关注点 A · 关闭思考 · 并发 10 · 输出预算 512 Token

局部劣化 · 待复测

### 32,768 字符档出现延迟抬升与吞吐回落

相邻已测区间：16,384 → 32,768 字符。后续 65,536 字符档恢复，当前不能认定为持续劣化转折点。

|                 |                  |                           |
|-----------------|------------------|---------------------------|
| TTFT P95        | E2E P95          | 聚合输出吞吐                    |
| +44.9%          | +20.8%           | -19.9%                    |
| 8.69 → 12.59 ms | 20.99 → 25.35 ms | 5,646.52 → 4,521.46 tok/s |

## 前一档、关注点与后一档一起看

| 输入字符   | TTFT P95 ms | E2E P95 ms | 聚合吞吐 tok/s | 成功 / 发起 |
|--------|-------------|------------|------------|---------|
| 16,384 | 8.69        | 20.99      | 5,646.52   | 30 / 30 |
| 32,768 | 12.59       | 25.35      | 4,521.46   | 30 / 30 |
| 65,536 | 9.74        | 22.10      | 5,498.21   | 30 / 30 |

数据来自第 4-6 页。变化率 = (关注点 - 前一档) / 前一档；仅比较相同模式、并发与输出预算。

## 01 已观测到什么

关闭思考、并发 10 时，输入从 16,384 增至 32,768 字符，TTFT P95 由 8.69 升至 12.59 ms（增加 3.90 ms，+44.9%），E2E P95 上升 20.8%，聚合吞吐下降 19.9%。这表示该已测点的尾部响应更慢、单位时间总产出减少；成功率仍为 100%。但单请求输出速率 P50 从 880.54 升至 917.64 tok/s，不能概括成所有指标都变差。

## 02 为什么暂不称为持续拐点

下一档 TTFT P95 回落至 9.74 ms，聚合吞吐回升至 5,498.21 tok/s。当前只看到一个局部低谷。每档仅 30 次请求、3 轮；没有逐轮波动分析或独立重复运行验证，不能声称统计显著。即便后续证据支持转折，也只能定位在相邻已测区间内，不能断言精确阈值。

## 03 对使用与复测的含义

如果业务常用约 32K 字符、并发 10，应优先复测该区间及两侧档位，增加独立重复运行，并核对实际输出长度、缓存、超时与失败情况。结合服务端和客户端监控定位原因；现有客户端汇总数据无法区分网络、调度与模型计算影响。

分析边界。以上结论仅覆盖本次已测条件；尚无独立重复运行验证。多项指标共同变化不等于已确定原因，也不能直接用于推断容量上限。

# 模型自评

让模型说说，这一轮表现如何

综合档位

人上人

模型主观自评

仅限本次已测范围 · 不构成排名或认证

依据本次汇总数据生成，未经事实核验。自评不计入性能统计，不改变运行状态。

## 01 表现较好的已测场景

在本次测试中，我完成了两种模式、7 档输入字符数与 3 档并发的全部 42 个组合，672 次性能请求均在协议层面完成。以 1,024 字符、并发 1 为例，关闭思考的 TTFT P50 为 6.81 ms、单请求输出速率 P50 为 875.79 tok/s。在这一已测场景下，我的首段响应较快，协议完成情况良好。不过实际输出较短，且单并发仅有 3 个样本，这些表现还不能代表长回答或长时间运行的结果。

## 02 输入与并发带来的压力

我会特别关注前页指出的局部劣化：关闭思考、并发 10，从 16,384 到 32,768 字符，TTFT P95 从 8.69 升至 12.59 ms (+44.9%)，聚合吞吐从 5,646.52 降至 4,521.46 tok/s (-19.9%)。这意味着该点的尾部响应更慢、单位时间总产出减少。不过单请求输出速率没有同步下降，65,536 字符档的尾延迟和聚合吞吐又恢复，不能据此宣称出现持续容量拐点。每档仅 30 次请求、3 轮，应先复测相邻区间，再判断变化是否稳定重现；客户端汇总数据也不足以定位硬件瓶颈。

## 03 思考模式的时间与预算代价

在相同的 1,024 字符、并发 1 条件下，开启思考的 TTFT P50 为 6.60 ms，而 TTFO P50 为 14.09 ms；关闭思考两项均为 6.81 ms。首段语义文本较早出现，不等于最终回答也同样早到达。同时，两模式输出预算为 512 与 4,096 Token，实际 completion\_tokens 的 P50 分别为 12 与 18，不能把所有差异归因于思考开关。未观测到关闭模式的思考内容，也不等于已经证明思考彻底关闭。

## 04 使用建议与证据限制

后续我建议先围绕实际业务的输入长度与目标并发补充样本，再共同观察 TTFO、E2E 尾延迟、截断和最终回答完整性。交互场景关注用户多久能看到最终回答，批处理场景则更关注聚合吞吐及完成情况。本次测试没有业务 SLA、长时间稳定性测试或硬件监控，因此不能给出生产容量承诺。我给出的档位是基于本次已测范围的主观评价，没有量化评分阈值，也不构成跨模型排名。

### 自评请求信息

被测模型根据本次汇总结果独立生成；关闭思考，输出上限 2,048 Token。评语未经事实核验，不计入性能统计，不改变运行状态。

# 测量口径与附录

定义、来源与缺失信息一起交付

## 测量口径与限制

- 1. TTFT 包括可识别的思考文本；TTFO 是首个可识别的最终回答。只有思考、没有最终回答或无法区分时，TTFO 为 N/A。
- 2. 所有耗时来自客户端单调时钟，包括连接、网络、网关、排队与处理；不是服务端纯计算时间。预检、生成材料、序列化与落盘不计入性能窗口。
- 3. 各组合测量窗口为每批最早请求发起至最后请求结束的时长之和；失败耗时保留在分母。
- 4. 单请求输出 tok/s = (服务输出 Token - 1) / 首末语义文本间隔（秒）；TPOT 为其倒数，以 ms/Token 表示。尾部 usage 和结束标记不延长生成时间。
- 5. 聚合输出 tok/s = 成功请求输出 Token 总数 / 组合测量窗口；任一成功请求缺少输出 usage 或存在未决请求时为 N/A。
- 6. Token 仅采用服务 usage；字符数与 SSE 分块数不是 Token 数。completion\_tokens 按服务口径展示，不能直接称为最终回答 Token。
- 7. 单块输出、少于 2 Token、零生成间隔或缺失 usage 时单请求速率为 N/A。思考被服务隐藏时，客户端无法完整观测生成过程。
- 8. 分布只包含成功且指标可计算的请求；P50/P95 使用 nearest-rank。默认单并发只有 3 个样本，尾延迟参考性有限。
- 9. 达到输出上限可属于协议成功；截断、最终回答缺失和未知分别保留。最高成功并发不代表绝对容量或模式已经验证。
- 10. 请求使用不同前缀，但不能强制关闭服务端缓存。固定执行顺序、不同输出预算和服务默认参数也可能影响对照。
- 11. N/A 表示缺少计算所需的完整观测，不表示 0；原始状态和原因保存在 requests.jsonl，分布样本数保存在 summary.json。

### 预检与预热

两种模式各执行 1 次预检，HTTP 200、无错误。本次未启用独立预热；预检不计入性能统计。

思考参数：chat\_template\_kwargs.enable\_thinking，分别使用 false / true。

### 自评与统计隔离

模型自评使用独立请求，关闭思考，输出上限 2,048 Token；不计入性能请求数、耗时分布或吞吐窗口。

档位与评语属于模型主观意见，不能替代原始证据核验。

### 运行与追溯信息

模型：Qwen3.8-27B  
Run：7c0816fbca63b913af909e13  
开始时间（UTC）：2026-09-09T05:59:49.642220+00:00  
指标来源：客户端请求时序与服务端 usage；计算口径见本页。  
核验材料：运行配置快照、请求级记录、汇总结果与自评记录应随报告一并归档。

### 支持 InferPulse Bench

如果工具对你有帮助，欢迎请作者喝一杯瑞幸咖啡。支持全凭自愿，不影响任何功能。

[gitee.com/xum1983/inferpulse-bench/blob/master/SPONSOR.md](https://gitee.com/xum1983/inferpulse-bench/blob/master/SPONSOR.md)