

大模型性能测试报告

Example-Model · 2026-09-21

42 / 42 已完成测试组合	378 / 378 性能请求协议完成	0 未决性能请求
--------------------	-----------------------	-------------

关键结论

- 常规测试：协议完成 378/378；截断 0 次，未产生最终回答 0 次。
- 长上下文：协议完成 72/72，截断 0 次。
- 多轮 Loop：协议完成 120/120，截断 0 次；工具闭环 24/24。

关键场景 · 双模式对照

1,024 字符 · 并发 1 · 共有的最低负载档位

关闭思考 输出预算 512 Token	开启思考 输出预算 4,096 Token
最终回答等待 P505.55 ms	最终回答等待 P5010.42 ms
请求耗时 P9512.26 ms	请求耗时 P9516.82 ms
单请求输出速率 P501861.54 tok/s	单请求输出速率 P50976.53 tok/s
实际输出 P5012.00 Token	实际输出 P5012.00 Token
协议完成 3/3 · 截断 0 · 最终回答 3	协议完成 3/3 · 截断 0 · 最终回答 3

性能变化分析

A 关闭思考 · 并发 1 · 8,192 → 16,384 字符		
TTFT P95		升高 599.1%
前一档 · 8,192 字符 5.63 ms	异常档 · 16,384 字符 39.39 ms	下一档 · 32,768 字符 39.31 ms
下一档仍差于前档，需复测确认。		
输出预算 512 Token · 前 / 后样本 3/3 · 截断 0/0 · 输出 Token P50 12.00/12.00		

B 开启思考 · 并发 1 · 8,192 → 16,384 字符

TTFT P95

前一档 · 8,192 字符

5.63 ms

异常档 · 16,384 字符

39.07 ms

下一档 · 32,768 字符

38.81 ms

升高 594.0%

下一档仍差于前档，需复测确认。

输出预算 4,096 Token · 前 / 后样本 3/3 · 截断 0/0 · 输出 Token P50 12.00/12.00

C 开启思考 · 输入 32768 字符 · 1 → 3 并发

TTFT P95

前一档 · 1 并发

38.81 ms

异常档 · 3 并发

132.36 ms

下一档 · 5 并发

40.37 ms

升高 241.1%

下一档仍差于前档，需复测确认。

输出预算 4,096 Token · 前 / 后样本 3/9 · 截断 0/0 · 输出 Token P50 12.00/12.00

测试条件与模式验证

测试条件	配置与记录
服务	http://127.0.0.1:8000/v1/chat/completions
Run	2982cdda80bda469e8ca15c3
执行状态	completed
输入字符档位	1024 / 2048 / 4096 / 8192 / 16384 / 32768 / 65536
并发 / 每组合轮数	1 / 3 / 5; 3 轮
输出预算	关闭思考 512 Token; 开启思考 4096 Token
执行顺序	关闭思考 → 开启思考
超时 (秒)	{"connect_seconds": 1, "read_seconds": 2, "total_seconds": 4}
输入生成器 / 种子	synthetic/v1 / test-seed
思考参数方案	qwen; 来源: model_name

关闭思考

预检成功：是；HTTP 接受参数：是；未观测到思考。

模式参数：{"chat_template_kwargs": {"enable_thinking": false}}

停止/结束原因：completed；预检 HTTP / 错误：200 / 无/未执行

开启思考

预检成功：是； HTTP 接受参数：是； 已观测到思考内容或服务返回的思考 Token。

模式参数： {"chat_template_kwargs": {"enable_thinking": true}}

停止/结束原因： completed； 预检 HTTP / 错误： 200 / 无/未执行

独立预热

本次未启用独立预热。

双模式对照

相同输入与并发并排展示。两种模式的预算、实际输出长度、模式验证及固定执行顺序均需一起解释。

最终回答等待 · TTFO P50（秒，越低越好）

	关闭思考	开启思考
1,024 字符 · 并发 1	0.01	0.01
1,024 字符 · 并发 3	0.01	0.01
1,024 字符 · 并发 5	0.01	0.01
2,048 字符 · 并发 1	0.01	0.01
2,048 字符 · 并发 3	0.01	0.01
2,048 字符 · 并发 5	0.01	0.01
4,096 字符 · 并发 1	0.01	0.01
4,096 字符 · 并发 3	0.01	0.01
4,096 字符 · 并发 5	0.01	0.01
8,192 字符 · 并发 1	0.01	0.01
8,192 字符 · 并发 3	0.01	0.01

最终回答等待 · TTFO P50 (秒, 越低越好)

	关闭思考	开启思考
8,192 字符 · 并发 5	0.01	0.01
16,384 字符 · 并发 1	A · 0.04	B · 0.04
16,384 字符 · 并发 3	0.04	0.04
16,384 字符 · 并发 5	0.04	0.04
32,768 字符 · 并发 1	0.04	0.04
32,768 字符 · 并发 3	0.04	C · 0.04
32,768 字符 · 并发 5	0.04	0.04
65,536 字符 · 并发 1	0.04	0.04
65,536 字符 · 并发 3	0.04	0.04
65,536 字符 · 并发 5	0.04	0.04

单请求输出速率 · P50 (tok/s, 越高越好)

	关闭思考	开启思考
1,024 字符 · 并发 1	1,862	976.53
1,024 字符 · 并发 3	1,752	981.43
1,024 字符 · 并发 5	1,802	975.86
2,048 字符 · 并发 1	1,762	969.77
2,048 字符 · 并发 3	1,808	973.47
2,048 字符 · 并发 5	1,737	964.55
4,096 字符 · 并发 1	1,762	966.74
4,096 字符 · 并发 3	1,804	969.05
4,096 字符 · 并发 5	1,775	973.92
8,192 字符 · 并发 1	1,759	972.75
8,192 字符 · 并发 3	1,758	970.49

单请求输出速率 · P50 (tok/s, 越高越好)

	关闭思考	开启思考
8,192 字符 · 并发 5	1,745	974.71
16,384 字符 · 并发 1	A · 1,916	B · 976.57
16,384 字符 · 并发 3	1,764	979.70
16,384 字符 · 并发 5	1,783	973.00
32,768 字符 · 并发 1	1,766	1,021
32,768 字符 · 并发 3	1,787	C · 977.84
32,768 字符 · 并发 5	1,774	977.96
65,536 字符 · 并发 1	1,757	973.27
65,536 字符 · 并发 3	1,820	969.08
65,536 字符 · 并发 5	1,757	990.54

延迟 · P50 ms

字符	并发	关闭思考 TTFT ms	开启思考 TTFT ms	关闭思考 TTFO ms	开启思考 TTFO ms
1024	1	5.55	5.44	5.55	10.42
1024	3	5.74	5.74	5.74	10.61
1024	5	5.93	5.81	5.93	10.50
2048	1	5.49	5.51	5.49	10.49
2048	3	5.90	5.77	5.90	10.74
2048	5	6.04	6.04	6.04	11.01
4096	1	5.60	5.48	5.60	10.55
4096	3	5.98	5.74	5.98	10.75
4096	5	6.18	5.95	6.18	10.81
8192	1	5.61	5.62	5.61	10.57
8192	3	5.96	5.89	5.96	10.83
8192	5	6.19	6.29	6.19	11.13
16384	1	38.93	38.91	38.93	43.56
16384	3	39.32	39.16	39.32	44.21
16384	5	39.66	38.27	39.66	43.28

字符	并发	关闭思考 TTFT ms	开启思考 TTFT ms	关闭思考 TTFO ms	开启思考 TTFO ms
32768	1	39.31	37.47	39.31	41.97
32768	3	39.74	39.66	39.74	44.63
32768	5	39.54	39.79	39.54	44.65
65536	1	39.18	39.29	39.18	44.26
65536	3	39.46	38.36	39.46	43.27
65536	5	39.55	39.88	39.55	44.82

输出 · P50


字符	并发	关闭思考 输出速率 tok/s	开启思考 输出速率 tok/s	关闭思考 输出 Token	开启思考 输出 Token
1024	1	1861.54	976.53	12.00	12.00
1024	3	1751.78	981.43	12.00	12.00
1024	5	1802.00	975.86	12.00	12.00
2048	1	1761.94	969.77	12.00	12.00
2048	3	1807.81	973.47	12.00	12.00
2048	5	1736.71	964.55	12.00	12.00
4096	1	1761.61	966.74	12.00	12.00
4096	3	1804.14	969.05	12.00	12.00
4096	5	1775.17	973.92	12.00	12.00
8192	1	1758.93	972.75	12.00	12.00
8192	3	1758.25	970.49	12.00	12.00
8192	5	1745.27	974.71	12.00	12.00
16384	1	1915.83	976.57	12.00	12.00
16384	3	1763.60	979.70	12.00	12.00
16384	5	1782.75	973.00	12.00	12.00
32768	1	1765.63	1021.32	12.00	12.00
32768	3	1787.27	977.84	12.00	12.00
32768	5	1774.09	977.96	12.00	12.00
65536	1	1757.12	973.27	12.00	12.00

字符	并发	关闭思考 输出速率 tok/s	开启思考 输出速率 tok/s	关闭思考 输出 Token	开启思考 输出 Token
65536	3	1820.04	969.08	12.00	12.00
65536	5	1757.19	990.54	12.00	12.00


关闭思考 · 性能明细

延迟单位 ms，速率 tok/s，TPOT ms/Token；分位数依次为 P50 / P95。


最终回答等待 · TTFO P95（秒，越低越好）



聚合输出吞吐 (tok/s, 越高越好)



首 Token 等待 · TTFT P95 (秒, 越低越好)



字符	并发	状态	发起 / 成功 / 未决	成功率	TTFT	TTFO	E2E
1024	1	completed	3/3/0	100.0%	5.55 / 5.94	5.55 / 5.94	11.51 / 12.26
1024	3	completed	9/9/0	100.0%	5.74 / 5.89	5.74 / 5.89	12.05 / 12.33
1024	5	completed	15/15/0	100.0%	5.93 / 6.13	5.93 / 6.13	12.09 / 12.70
2048	1	completed	3/3/0	100.0%	5.49 / 5.51	5.49 / 5.51	11.81 / 11.81
2048	3	completed	9/9/0	100.0%	5.90 / 6.10	5.90 / 6.10	12.01 / 12.43
2048	5	completed	15/15/0	100.0%	6.04 / 6.22	6.04 / 6.22	12.49 / 12.90
4096	1	completed	3/3/0	100.0%	5.60 / 5.63	5.60 / 5.63	11.83 / 11.94
4096	3	completed	9/9/0	100.0%	5.98 / 6.19	5.98 / 6.19	12.23 / 12.53
4096	5	completed	15/15/0	100.0%	6.18 / 6.52	6.18 / 6.52	12.57 / 13.15
8192	1	completed	3/3/0	100.0%	5.61 / 5.63	5.61 / 5.63	11.23 / 11.92
8192	3	completed	9/9/0	100.0%	5.96 / 6.12	5.96 / 6.12	12.47 / 12.55
8192	5	completed	15/15/0	100.0%	6.19 / 6.48	6.19 / 6.48	12.60 / 12.96
A 16384	1	completed	3/3/0	100.0%	38.93 / 39.39	38.93 / 39.39	44.71 / 46.60
16384	3	completed	9/9/0	100.0%	39.32 / 39.71	39.32 / 39.71	45.44 / 46.05
16384	5	completed	15/15/0	100.0%	39.66 / 40.49	39.66 / 40.49	46.13 / 47.03
32768	1	completed	3/3/0	100.0%	39.31 / 39.31	39.31 / 39.31	45.64 / 45.66
32768	3	completed	9/9/0	100.0%	39.74 / 40.16	39.74 / 40.16	46.17 / 46.89
32768	5	completed	15/15/0	100.0%	39.54 / 40.55	39.54 / 40.55	45.74 / 46.73
65536	1	completed	3/3/0	100.0%	39.18 / 39.60	39.18 / 39.60	45.51 / 45.95

字符	并发	状态	发起 / 成功 / 未决	成功率	TTFT	TTFO	E2E
65536	3	completed	9/9/0	100.0%	39.46 / 40.28	39.46 / 40.28	45.58 / 46.56
65536	5	completed	15/15/0	100.0%	39.55 / 41.02	39.55 / 41.02	46.07 / 47.35

输出速率与服务端 Token

字符	并发	单请求速率	TPOT	聚合吞吐	输入 Token P50	输出 Token P50
1024	1	1861.54 / 2108.41	0.54 / 0.57	1041.59	50.00	12.00
1024	3	1751.78 / 1834.63	0.57 / 0.57	2947.32	50.00	12.00
1024	5	1802.00 / 2143.48	0.55 / 0.58	4831.38	50.00	12.00
2048	1	1761.94 / 2000.17	0.57 / 0.57	1038.55	50.00	12.00
2048	3	1807.81 / 1997.35	0.55 / 0.57	2953.84	50.00	12.00
2048	5	1736.71 / 1853.67	0.58 / 0.62	4661.82	50.00	12.00
4096	1	1761.61 / 1887.35	0.57 / 0.57	1021.34	50.00	12.00
4096	3	1804.14 / 1845.99	0.55 / 0.57	2897.13	50.00	12.00
4096	5	1775.17 / 1862.97	0.56 / 0.62	4642.02	50.00	12.00
8192	1	1758.93 / 1984.34	0.57 / 0.57	1047.03	50.00	12.00
8192	3	1758.25 / 1769.94	0.57 / 0.59	2865.38	50.00	12.00
8192	5	1745.27 / 2195.86	0.57 / 0.62	4644.02	50.00	12.00
A 16384	1	1915.83 / 2082.63	0.52 / 0.64	265.48	50.00	12.00
16384	3	1763.60 / 2159.60	0.57 / 0.58	783.26	50.00	12.00
16384	5	1782.75 / 1864.78	0.56 / 0.59	1280.21	50.00	12.00

字符	并发	单请求速率	TPOT	聚合吞吐	输入 Token P50	输出 Token P50
32768	1	1765.63 / 1777.95	0.57 / 0.57	263.14	50.00	12.00
32768	3	1787.27 / 2100.74	0.56 / 0.60	773.15	50.00	12.00
32768	5	1774.09 / 2128.86	0.56 / 0.60	1289.38	50.00	12.00
65536	1	1757.12 / 1762.31	0.57 / 0.57	269.33	50.00	12.00
65536	3	1820.04 / 1970.46	0.55 / 0.57	779.90	50.00	12.00
65536	5	1757.19 / 1969.43	0.57 / 0.60	1275.19	50.00	12.00

证据完整性

字符	并发	思考 / 缓存 Token P50	usage 覆盖	最终回答 / 未知	截断	速率有效样本
1024	1	0.00/N/A	100.0%	3/0	0	3
1024	3	0.00/N/A	100.0%	9/0	0	9
1024	5	0.00/N/A	100.0%	15/0	0	15
2048	1	0.00/N/A	100.0%	3/0	0	3
2048	3	0.00/N/A	100.0%	9/0	0	9
2048	5	0.00/N/A	100.0%	15/0	0	15
4096	1	0.00/N/A	100.0%	3/0	0	3
4096	3	0.00/N/A	100.0%	9/0	0	9
4096	5	0.00/N/A	100.0%	15/0	0	15
8192	1	0.00/N/A	100.0%	3/0	0	3
8192	3	0.00/N/A	100.0%	9/0	0	9
8192	5	0.00/N/A	100.0%	15/0	0	15
A 16384	1	0.00/N/A	100.0%	3/0	0	3
16384	3	0.00/N/A	100.0%	9/0	0	9
16384	5	0.00/N/A	100.0%	15/0	0	15
32768	1	0.00/N/A	100.0%	3/0	0	3


字符	并发	思考 / 缓存 Token P50	usage 覆盖	最终回答 / 未知	截断	速率有效样本
32768	3	0.00/N/A	100.0%	9/0	0	9
32768	5	0.00/N/A	100.0%	15/0	0	15
65536	1	0.00/N/A	100.0%	3/0	0	3
65536	3	0.00/N/A	100.0%	9/0	0	9
65536	5	0.00/N/A	100.0%	15/0	0	15

最高全部请求协议成功的已测并发：1024 字符：5；2048 字符：5；4096 字符：5；8192 字符：5；16384 字符：5；32768 字符：5；65536 字符：5。


开启思考 · 性能明细

延迟单位 ms，速率 tok/s，TPOT ms/Token；分位数依次为 P50 / P95。


最终回答等待 · TTFO P95（秒，越低越好）



聚合输出吞吐（tok/s，越高越好）



首 Token 等待 · TTFT P95 (秒, 越低越好)



字符	并发	状态	发起 / 成功 / 未决	成功率	TTFT	TTFO	E2E
1024	1	completed	3/3/0	100.0%	5.44 / 5.51	10.42 / 10.45	16.74 / 16.82
1024	3	completed	9/9/0	100.0%	5.74 / 5.93	10.61 / 10.92	17.09 / 17.33
1024	5	completed	15/15/0	100.0%	5.81 / 6.32	10.50 / 11.23	16.87 / 17.58
2048	1	completed	3/3/0	100.0%	5.51 / 5.58	10.49 / 10.61	16.92 / 16.95
2048	3	completed	9/9/0	100.0%	5.77 / 5.89	10.74 / 10.82	17.16 / 17.33
2048	5	completed	15/15/0	100.0%	6.04 / 6.27	11.01 / 11.22	17.56 / 18.05
4096	1	completed	3/3/0	100.0%	5.48 / 5.57	10.55 / 10.56	16.91 / 16.94
4096	3	completed	9/9/0	100.0%	5.74 / 5.84	10.75 / 10.89	17.23 / 17.48
4096	5	completed	15/15/0	100.0%	5.95 / 6.21	10.81 / 11.16	17.16 / 17.81
8192	1	completed	3/3/0	100.0%	5.62 / 5.63	10.57 / 10.61	16.92 / 16.97
8192	3	completed	9/9/0	100.0%	5.89 / 6.03	10.83 / 11.03	17.27 / 17.55
8192	5	completed	15/15/0	100.0%	6.29 / 6.67	11.13 / 11.58	17.76 / 18.07
B 16384	1	completed	3/3/0	100.0%	38.91 / 39.07	43.56 / 43.85	50.02 / 50.24
16384	3	completed	9/9/0	100.0%	39.16 / 40.26	44.21 / 45.16	50.54 / 51.40
16384	5	completed	15/15/0	100.0%	38.27 / 39.94	43.28 / 44.91	49.29 / 51.37
32768	1	completed	3/3/0	100.0%	37.47 / 38.81	41.97 / 43.64	48.31 / 49.98
C 32768	3	completed	9/9/0	100.0%	39.66 / 132.36	44.63 / 149.42	50.64 / 153.93
32768	5	completed	15/15/0	100.0%	39.79 / 40.37	44.65 / 44.96	51.14 / 52.08
65536	1	completed	3/3/0	100.0%	39.29 / 40.27	44.26 / 45.52	50.69 / 52.14

字符	并发	状态	发起 / 成功 / 未决	成功率	TTFT	TTFO	E2E
65536	3	completed	9/9/0	100.0%	38.36 / 40.04	43.27 / 45.21	50.03 / 51.48
65536	5	completed	15/15/0	100.0%	39.88 / 41.83	44.82 / 46.86	51.09 / 53.26

输出速率与服务端 Token

字符	并发	单请求速率	TPOT	聚合吞吐	输入 Token P50	输出 Token P50
1024	1	976.53 / 1016.02	1.02 / 1.03	721.83	50.00	12.00
1024	3	981.43 / 1031.82	1.02 / 1.04	2107.02	50.00	12.00
1024	5	975.86 / 1054.73	1.02 / 1.07	3466.76	50.00	12.00
2048	1	969.77 / 971.23	1.03 / 1.03	710.94	50.00	12.00
2048	3	973.47 / 992.13	1.03 / 1.05	2089.31	50.00	12.00
2048	5	964.55 / 1010.00	1.04 / 1.08	3343.64	50.00	12.00
4096	1	966.74 / 971.27	1.03 / 1.04	712.92	50.00	12.00
4096	3	969.05 / 1040.34	1.03 / 1.06	2072.38	50.00	12.00
4096	5	973.92 / 1032.04	1.03 / 1.05	3420.82	50.00	12.00
8192	1	972.75 / 1075.72	1.03 / 1.03	722.66	50.00	12.00
8192	3	970.49 / 1088.73	1.03 / 1.06	2086.40	50.00	12.00
8192	5	974.71 / 1009.22	1.03 / 1.06	3321.64	50.00	12.00
B 16384	1	976.57 / 1012.97	1.02 / 1.02	245.97	50.00	12.00
16384	3	979.70 / 1087.56	1.02 / 1.03	704.90	50.00	12.00
16384	5	973.00 / 1093.32	1.03 / 1.09	1170.73	50.00	12.00
32768	1	1021.32 / 1030.71	0.98 / 1.01	246.23	50.00	12.00
C 32768	3	977.84 / 1063.67	1.02 / 1.99	419.88	50.00	12.00
32768	5	977.96 / 1132.59	1.02 / 1.09	1160.21	50.00	12.00
65536	1	973.27 / 978.92	1.03 / 1.05	235.87	50.00	12.00
65536	3	969.08 / 1195.40	1.03 / 1.06	705.41	50.00	12.00
65536	5	990.54 / 1072.28	1.01 / 1.05	1140.66	50.00	12.00

证据完整性

字符	并发	思考 / 缓存 Token P50	usage 覆盖	最终回答 / 未知	截断	速率有效样本
1024	1	3.00/N/A	100.0%	3/0	0	3
1024	3	3.00/N/A	100.0%	9/0	0	9
1024	5	3.00/N/A	100.0%	15/0	0	15
2048	1	3.00/N/A	100.0%	3/0	0	3
2048	3	3.00/N/A	100.0%	9/0	0	9
2048	5	3.00/N/A	100.0%	15/0	0	15
4096	1	3.00/N/A	100.0%	3/0	0	3
4096	3	3.00/N/A	100.0%	9/0	0	9
4096	5	3.00/N/A	100.0%	15/0	0	15
8192	1	3.00/N/A	100.0%	3/0	0	3
8192	3	3.00/N/A	100.0%	9/0	0	9
8192	5	3.00/N/A	100.0%	15/0	0	15
B 16384	1	3.00/N/A	100.0%	3/0	0	3
16384	3	3.00/N/A	100.0%	9/0	0	9
16384	5	3.00/N/A	100.0%	15/0	0	15
32768	1	3.00/N/A	100.0%	3/0	0	3
C 32768	3	3.00/N/A	100.0%	9/0	0	9
32768	5	3.00/N/A	100.0%	15/0	0	15
65536	1	3.00/N/A	100.0%	3/0	0	3
65536	3	3.00/N/A	100.0%	9/0	0	9
65536	5	3.00/N/A	100.0%	15/0	0	15

最高全部请求协议成功的已测并发：1024 字符：5；2048 字符：5；4096 字符：5；8192 字符：5；16384 字符：5；32768 字符：5；65536 字符：5。

Agent 能力评估

专项总结


多轮 Loop，开启思考，并发 1：第 1 → 4 轮工具就绪 P95 19.17 → 31.96 ms，变化 +66.7%；有效样本 3/3，实际输入 Token P50 150.00/600.00。

专项每次模型调用输出上限（含思考）：关闭思考 512 Token；开启思考 4096 Token。


新增性能请求上限 168；引用常规请求 24；独立预检/预热上限 8/0。实际新增请求 176，观测峰值在途请求 3。

长上下文

聚合吞吐 (tok/s) · 关闭 / 开启思考



聚合吞吐 (tok/s) · 关闭 / 开启思考



模式 / 负载 / 并发	来源	成功/尝试	TTFT P95 ms	TTFO P95 ms	E2E P95 ms
关闭思考 / 128 字符 / 1	专项实测	3/3 (completed)	6.80	6.80	13.23


模式 / 负载 / 并发	来源	成功/尝试	TTFT P95 ms	TTFO P95 ms	E2E P95 ms
关闭思考 / 128 字符 / 3	专项实测	9/9 (completed)	7.52	7.52	14.36
关闭思考 / 512 字符 / 1	专项实测	3/3 (completed)	5.64	5.64	11.70
关闭思考 / 512 字符 / 3	专项实测	9/9 (completed)	5.93	5.93	12.33
关闭思考 / 2048 字符 / 1	常规基线引用	3/3 (completed)	5.51	5.51	11.81
关闭思考 / 2048 字符 / 3	常规基线引用	9/9 (completed)	6.10	6.10	12.43
开启思考 / 128 字符 / 1	专项实测	3/3 (completed)	5.67	10.72	17.05
开启思考 / 128 字符 / 3	专项实测	9/9 (completed)	6.17	11.16	17.35
开启思考 / 512 字符 / 1	专项实测	3/3 (completed)	5.62	10.65	16.94
开启思考 / 512 字符 / 3	专项实测	9/9 (completed)	5.93	10.78	17.23
开启思考 / 2048 字符 / 1	常规基线引用	3/3 (completed)	5.58	10.61	16.95
开启思考 / 2048 字符 / 3	常规基线引用	9/9 (completed)	5.89	10.82	17.33

模式 / 负载 / 并发	单请求 tok/s P50	聚合 tok/s	输入/输出 Token P50	usage 覆盖	截断
关闭思考 / 128 / 1	1748.52	956.82	50.00/12.00	100.0%	0
关闭思考 / 128 / 3	1760.15	2602.32	50.00/12.00	100.0%	0
关闭思考 / 512 / 1	1833.49	1047.75	50.00/12.00	100.0%	0
关闭思考 / 512 / 3	1775.54	2927.89	50.00/12.00	100.0%	0
关闭思考 / 2048 / 1	1761.94	1038.55	50.00/12.00	100.0%	0
关闭思考 / 2048 / 3	1807.81	2953.84	50.00/12.00	100.0%	0
开启思考 / 128 / 1	970.30	708.13	50.00/12.00	100.0%	0
开启思考 / 128 / 3	969.56	2066.18	50.00/12.00	100.0%	0
开启思考 / 512 / 1	967.09	726.44	50.00/12.00	100.0%	0

模式 / 负载 / 并发	单请求 tok/s P50	聚合 tok/s	输入/输出 Token P50	usage 覆盖	截断
开启思考 / 512 / 3	978.71	2116.60	50.00/12.00	100.0%	0
开启思考 / 2048 / 1	969.77	710.94	50.00/12.00	100.0%	0
开启思考 / 2048 / 3	973.47	2089.31	50.00/12.00	100.0%	0

多轮 Loop

聚合吞吐 (tok/s) · 关闭 / 开启思考



工具调用方式：自动选择（auto）；每轮显式请求一次工具调用，最后一轮明确要求总结并关闭工具。

模式 / 负载 / 并发	来源	成功/尝试	TTFT P95 ms	TTFO P95 ms	E2E P95 ms
关闭思考 / 128 字符 / 1	专项实测	15/15 (completed)	6.09	6.09	15.46
关闭思考 / 128 字符 / 3	专项实测	45/45 (completed)	5.83	5.83	13.70
开启思考 / 128 字符 / 1	专项实测	15/15 (completed)	18.81	11.54	32.10
开启思考 / 128 字符 / 3	专项实测	45/45 (completed)	6.81	11.82	19.14


模式 / 负载 / 并发	单请求 tok/s P50	聚合 tok/s	输入/输出 Token P50	usage 覆盖	截断
关闭思考 / 128 / 1	1911.08	639.37	450.00/12.00	100.0%	0
关闭思考 / 128 / 3	1760.28	1918.98	450.00/12.00	100.0%	0
开启思考 / 128 / 1	971.96	476.29	450.00/12.00	100.0%	0
开启思考 / 128 / 3	967.18	1485.86	450.00/12.00	100.0%	0

关闭思考 · 并发 1 · Loop 逐轮

完整流程 3/3，未决会话 0；流程耗时 P50/P95 91.01/100.38 ms；完整流程吞吐 639.37 次/分钟。

完整会话累计输入/输出 Token P50：2250.00/60.00；累计思考/缓存 Token P50：0.00/N/A。

工具调用就绪时间 P95（ms）随轮次变化




轮次 / 输出	成功/到达	输入字符/Token P50	工具就绪 P95 ms	E2E P95 ms	单请求 tok/s P50
1 / 工具	3/3	490.00/150.00	13.56	13.70	N/A
2 / 工具	3/3	725.00/300.00	15.27	15.46	N/A
3 / 工具	3/3	960.00/450.00	14.28	14.40	N/A
4 / 工具	3/3	1195.00/600.00	13.98	14.04	N/A
5 / 最终回答	3/3	1482.00/750.00	N/A	12.44	1911.08

关闭思考 · 并发 3 · Loop 逐轮

完整流程 9/9，未决会话 0；流程耗时 P50/P95 92.70/96.40 ms；完整流程吞吐 1918.98 次/分钟。

完整会话累计输入/输出 Token P50：2250.00/60.00；累计思考/缓存 Token P50：0.00/N/A。

工具调用就绪时间 P95（ms）随轮次变化




轮次 / 输出	成功/到达	输入字符/Token P50	工具就绪 P95 ms	E2E P95 ms	单请求 tok/s P50
1 / 工具	9/9	490.00/150.00	13.55	13.59	N/A
2 / 工具	9/9	725.00/300.00	13.59	13.70	N/A
3 / 工具	9/9	960.00/450.00	13.59	13.64	N/A
4 / 工具	9/9	1195.00/600.00	13.65	13.82	N/A
5 / 最终回答	9/9	1482.00/750.00	N/A	12.26	1760.28

开启思考 · 并发 1 · Loop 逐轮

完整流程 3/3，未决会话 0；流程耗时 P50/P95 127.79/134.16 ms；完整流程吞吐 476.29 次/分钟。

完整会话累计输入/输出 Token P50：2250.00/60.00；累计思考/缓存 Token P50：15.00/N/A。

工具调用就绪时间 P95（ms）随轮次变化




轮次 / 输出	成功/到达	输入字符/Token P50	工具就绪 P95 ms	E2E P95 ms	单请求 tok/s P50
1 / 工具	3/3	490.00/150.00	19.17	19.29	N/A
2 / 工具	3/3	748.00/300.00	20.37	20.54	N/A
3 / 工具	3/3	1006.00/450.00	19.78	19.92	N/A
4 / 工具	3/3	1264.00/600.00	31.96	32.10	N/A
5 / 最终回答	3/3	1574.00/750.00	N/A	17.86	971.96

开启思考 · 并发 3 · Loop 逐轮

完整流程 9/9，未决会话 0；流程耗时 P50/P95 121.32/122.36 ms；完整流程吞吐 1485.86 次/分钟。

完整会话累计输入/输出 Token P50：2250.00/60.00；累计思考/缓存 Token P50：15.00/N/A。

工具调用就绪时间 P95（ms）随轮次变化



轮次 / 输出	成功/到达	输入字符/Token P50	工具就绪 P95 ms	E2E P95 ms	单请求 tok/s P50
1 / 工具	9/9	490.00/150.00	18.78	18.82	N/A
2 / 工具	9/9	748.00/300.00	19.37	19.41	N/A
3 / 工具	9/9	1006.00/450.00	19.38	19.46	N/A
4 / 工具	9/9	1264.00/600.00	18.87	19.14	N/A
5 / 最终回答	9/9	1574.00/750.00	N/A	18.27	967.18

思考模式对照

各列依次为关闭/开启思考；输出预算和实际生成长度须一起比较。

调用耗时 · E2E P95（秒，越低越好）

	关闭思考	开启思考
长上下文 · 128 字符 · 并发 1	0.01	0.02
长上下文 · 128 字符 · 并发 3	0.01	0.02
长上下文 · 512 字符 · 并发 1	0.01	0.02
长上下文 · 512 字符 · 并发 3	0.01	0.02
长上下文 · 2,048 字符 · 并发 1	0.01	0.02
长上下文 · 2,048 字符 · 并发 3	0.01	0.02
多轮 Loop · 128 字符 · 并发 1	0.02	0.03
多轮 Loop · 128 字符 · 并发 3	0.01	0.02

聚合输出吞吐（tok/s，越高越好）

	关闭思考	开启思考
长上下文 · 128 字符 · 并发 1	956.82	708.13
长上下文 · 128 字符 · 并发 3	2,602	2,066
长上下文 · 512 字符 · 并发 1	1,048	726.44
长上下文 · 512 字符 · 并发 3	2,928	2,117
长上下文 · 2,048 字符 · 并发 1	1,039	710.94
长上下文 · 2,048 字符 · 并发 3	2,954	2,089
多轮 Loop · 128 字符 · 并发 1	639.37	476.29
多轮 Loop · 128 字符 · 并发 3	1,919	1,486

场景 / 负载 / 并发	输出预算	E2E P95 ms	聚合 tok/s	输出 Token P50
长上下文 / 128 / 1	512/4096	13.23/17.05	956.82/708.13	12.00/12.00
长上下文 / 128 / 3	512/4096	14.36/17.35	2602.32/2066.18	12.00/12.00
长上下文 / 512 / 1	512/4096	11.70/16.94	1047.75/726.44	12.00/12.00
长上下文 / 512 / 3	512/4096	12.33/17.23	2927.89/2116.60	12.00/12.00
长上下文 / 2048 / 1	512/4096	11.81/16.95	1038.55/710.94	12.00/12.00
长上下文 / 2048 / 3	512/4096	12.43/17.33	2953.84/2089.31	12.00/12.00
多轮 Loop / 128 / 1	512/4096	15.46/32.10	639.37/476.29	12.00/12.00
多轮 Loop / 128 / 3	512/4096	13.70/19.14	1918.98/1485.86	12.00/12.00

模型自评

让模型说说，这一轮表现如何

综合档位：

人上人

模型主观自评

仅限本次已测范围 · 不构成排名或认证

依据本次常规汇总数据生成，未经事实核验；不计入性能统计，不改变运行状态。

1. 响应与交互

低负载下可以快速返回首段内容。开启思考后，首个语义文本与最终回答的等待时间不同，应根据业务交互方式分别关注 TTFT 与 TTFO。

2. 长上下文变化

输入从 8,192 增至 16,384 字符时出现明显等待时间上升。当前结果只能定位变化区间，仍需控制缓存、输出长度和其他负载后复测原因。

3. 并发与容量

各档位请求完成不代表已测得绝对容量。上线前应结合业务超时限制、尾延迟和实际输出长度确定并发，并预留资源余量。

4. Agent 工具闭环

工具调用、结果回填和最终收尾在已测流程中完成。这个结果说明固定协议链路可运行，复杂任务的答案质量需要另行评估。

5. 使用建议

优先采用符合响应目标的负载档位；思考模式按任务需求选择。保留请求级证据，对长上下文转折区间进行重复验证。

自评请求信息

请求设置：关闭思考；输出上限 2048 Token；使用本次配置的超时；不重试。

测量口径与附录

图中 * / 空心点：含截断、未完成或有效样本少于 3；— / 断线：缺少指标。准确值及样本见明细。

TTFT 为首个语义 Token（含可见思考），TTFO 为首个最终回答；耗时由客户端观测，包含网络、排队与处理，不含预检、预热和落盘。

Token 采用服务 usage；字符与分块不是 Token，输出用量可能包含思考。单请求 tok/s = (输出 Token - 1) / 首末语义文本间隔；TPOT = 1000 / tok/s。

聚合 tok/s = 成功请求输出 Token 总量 / 各批首发至未结束的时长之和，含失败耗时。缺用量、未决请求或生成区间不可算时，对应指标为 N/A，不是 0。

P50/P95 取可计算的成功样本（nearest-rank）；小样本尾延迟仅供参考。协议成功不等于回答完整，最高已测并发不是容量上限。

对照须结合输出预算、实际长度、执行顺序与缓存；未观测到思考不证明已关闭。异常关注相邻完整组合的 TTFT/E2E P95 上升或聚合吞吐下降 $\geq 20\%$ （各 ≥ 3 样本），不代表统计显著性或原因判定。

复核依据：requests.jsonl 保存请求状态与时序，summary.json 保存样本数、汇总及规则观察。

Agent：仅测性能与协议流程，不评价答案质量；基线引用不重复计数。预检失败不直接证明模型不支持。

Loop 并发为初始会话数，吞吐窗口含工具、轮间等待和失败；累计输入含重复历史。工具轮与最终回答分开比较，证据见 agent_requests.jsonl。

如果 InferPulse Bench 帮到了你，欢迎[打开支持页面](#)，请作者喝一杯瑞幸咖啡。支持全凭自愿，不影响任何功能的使用。